I. Tổng quan về Object Detection trong Computer Vision

Khái niệm Object Detection:

Trong lĩnh vực thị giác máy tính (Computer Vision), phát hiện đối tượng (Object Detection) là bài toán nhằm xác định sự xuất hiện và vị trí của các đối tượng trong hình ảnh hoặc video[1]. Khác với bài toán phân loại ảnh (Image Classification) chỉ dự đoán một nhãn cho toàn bộ hình ảnh, object detection yêu cầu hệ thống phải nhận diện từng đối tượng riêng lẻ và xác định vị trí của chúng trong ảnh.

Thông thường, vị trí của các đối tượng được biểu diễn bằng bounding box – các khung hình chữ nhật bao quanh đối tượng. Nhờ vậy, mô hình có thể vừa xác định loại đối tượng vừa chỉ ra tọa độ của chúng trong ảnh.

Ví dụ, trong một bức ảnh chụp đường phố, mô hình object detection có thể phát hiện nhiều loại đối tượng khác nhau như ô tô, người đi bộ, xe máy hoặc biển báo giao thông, đồng thời đánh dấu vị trí của từng đối tượng trên ảnh.

Phân biệt Image Classification, Object Localization và Object Detection

- Image Classification

Image classification là bài toán trong đó mô hình gán một nhãn cho toàn bộ hình ảnh dựa trên nội dung của nó. Ví dụ, một bức ảnh có thể được phân loại là “mèo”, “chó” hoặc “xe hơi”. Tuy nhiên, phương pháp này không cung cấp thông tin về vị trí của đối tượng trong ảnh.

- Object Localization

Object localization mở rộng từ bài toán phân loại ảnh bằng cách xác định vị trí của đối tượng chính trong ảnh. Ngoài việc dự đoán nhãn của đối tượng, mô hình còn dự đoán một bounding box bao quanh đối tượng đó.

- Object Detection

Object detection là sự kết hợp của hai nhiệm vụ trên. Phương pháp này không chỉ xác định loại đối tượng mà còn phát hiện nhiều đối tượng khác nhau trong cùng một hình ảnh và xác định vị trí của từng đối tượng. Kết quả đầu ra của object detection thường bao gồm:

- Nhãn của đối tượng
- Tọa độ bounding box

- Độ tin cậy của dự đoán

- Quy trình hoạt động của Object Detection

Quá trình phát hiện đối tượng thường bao gồm một số bước cơ bản sau:

1. Input Image

Hệ thống nhận vào hình ảnh hoặc khung hình từ video làm dữ liệu đầu vào cho quá trình xử lý.

2. Pre-processing

Ở bước này, hình ảnh được chuẩn hóa hoặc biến đổi để phù hợp với yêu cầu của mô hình, chẳng hạn như thay đổi kích thước ảnh, chuẩn hóa giá trị pixel hoặc tăng cường dữ liệu.

3. Feature Extraction

Mạng neural, thường là CNN (Convolutional Neural Network), được sử dụng để trích xuất các đặc trưng quan trọng từ hình ảnh. Các đặc trưng này giúp mô hình nhận biết các đối tượng khác nhau trong ảnh.

4. Classification

Sau khi đặc trưng được trích xuất, mô hình sẽ phân loại từng vùng trong ảnh để xác định loại đối tượng có thể xuất hiện tại vị trí đó.

5. Localization

Ở bước này, mô hình dự đoán tọa độ của các bounding box nhằm xác định vị trí của đối tượng trong hình ảnh.

6. Non-Maximum Suppression (NMS)

Trong nhiều trường hợp, mô hình có thể dự đoán nhiều bounding box cho cùng một đối tượng. Thuật toán Non-Maximum Suppression (NMS) được sử dụng để loại bỏ các bounding box trùng lặp và chỉ giữ lại dự đoán có độ tin cậy cao nhất.

7. Output

Kết quả cuối cùng là hình ảnh đầu vào được đánh dấu bằng các bounding box và nhãn tương ứng, thể hiện các đối tượng được phát hiện trong ảnh.

Các phương pháp Deep Learning cho Object Detection

Các phương pháp phát hiện đối tượng dựa trên deep learning có thể được chia thành hai nhóm chính: **two-stage detectors và single-stage detectors**.

- Two-Stage Detectors

Các mô hình thuộc nhóm này hoạt động theo hai bước chính:

1. Xác định các vùng trong ảnh có khả năng chứa đối tượng (region proposals).
2. Phân loại các vùng đó và dự đoán bounding box chính xác.

Một số mô hình tiêu biểu trong nhóm này gồm:

- R-CNN
- Fast R-CNN
- Faster R-CNN

Một số mô hình Two-Stage phổ biến

R-CNN

R-CNN là một trong những phương pháp đầu tiên áp dụng deep learning cho object detection. Mô hình sử dụng Selective Search để tạo ra khoảng vài nghìn vùng đề xuất có khả năng chứa đối tượng[2]. Sau đó, mỗi vùng được đưa qua một mạng CNN để trích xuất đặc trưng và tiến hành phân loại.

Fast R-CNN

Fast R-CNN cải tiến từ R-CNN bằng cách xử lý toàn bộ hình ảnh qua CNN chỉ một lần để tạo ra feature map. Sau đó, các vùng đề xuất được ánh xạ lên feature map và trích xuất đặc trưng thông qua ROI Pooling[3]. Mạng sau đó dự đoán cả xác suất lớp và bounding box cho từng vùng.

Faster R-CNN

Faster R-CNN tiếp tục cải tiến bằng cách thay thế Selective Search bằng Region Proposal Network (RPN)[4]. RPN được tích hợp trực tiếp vào mạng neural và có nhiệm vụ tạo ra các vùng đề xuất từ feature map, giúp tăng tốc độ và hiệu quả của quá trình phát hiện đối tượng.

- Single-Stage Detectors

Khác với các mô hình hai giai đoạn, single-stage detectors thực hiện dự đoán bounding box và phân loại đối tượng trong một bước duy nhất. Điều này giúp các mô hình loại này đạt tốc độ xử lý nhanh hơn, phù hợp với các ứng dụng thời gian thực.

Hai mô hình phổ biến thuộc nhóm này là:

- SSD (Single Shot MultiBox Detector)
- YOLO (You Only Look Once)

SSD (Single Shot MultiBox Detector)

SSD là mô hình phát hiện đối tượng thực hiện dự đoán bounding box và xác suất lớp trực tiếp từ các feature map ở nhiều kích thước khác nhau. Nhờ sử dụng nhiều mức đặc trưng, SSD có khả năng phát hiện đối tượng với kích thước khác nhau trong ảnh[5].

YOLO (You Only Look Once)

YOLO là một kiến trúc phát hiện đối tượng một giai đoạn rất nổi tiếng. Phương pháp này chia hình ảnh thành các ô lưới (grid cells), và mỗi ô lưới sẽ dự đoán bounding box cùng với xác suất của các lớp đối tượng. Toàn bộ quá trình dự đoán được thực hiện trong một lần chạy của mạng, giúp YOLO đạt tốc độ rất cao và phù hợp với các ứng dụng thời gian thực[6].

II. Tìm hiểu kiến trúc YOLOv3

Giới thiệu về YOLOv3

YOLOv3 là một trong những mô hình phát hiện đối tượng (object detection) nổi bật trong lĩnh vực thị giác máy tính. Mô hình này được phát triển bởi Joseph Redmon và cộng sự với mục tiêu cải thiện cả tốc độ xử lý và độ chính xác so với các phiên bản trước[7].

YOLOv3 thuộc nhóm single-stage detector, nghĩa là việc dự đoán vị trí và loại đối tượng được thực hiện trong một lần chạy duy nhất của mạng neural. Điều này giúp mô hình đạt tốc độ xử lý cao và phù hợp với các ứng dụng thời gian thực như giám sát giao thông, xe tự lái hoặc hệ thống an ninh.

Khác với các phương pháp two-stage như Faster R-CNN, YOLOv3 không cần bước đề xuất vùng (region proposal) mà trực tiếp dự đoán bounding box và xác suất lớp từ đặc trưng của ảnh[4].

Cấu trúc tổng thể của YOLOv3

Kiến trúc của YOLOv3 bao gồm ba thành phần chính:

1. **Backbone (mạng trích xuất đặc trưng)**
2. **Neck (tổng hợp đặc trưng đa tỷ lệ)**
3. **Detection Head (dự đoán bounding box và class)**

Quy trình xử lý của YOLOv3 có thể mô tả như sau:

Input Image
↓
Backbone (Darknet-53)
↓
Feature Maps
↓
Multi-scale Feature Fusion
↓
Detection Heads (3 scales)
↓
Bounding Boxes + Class Probabilities

Backbone: Darknet-53

Backbone của YOLOv3 là mạng Darknet-53, một mạng CNN sâu gồm 53 lớp convolution[7].

	Type	Filters	Size	Output
	Convolutional	32	3 × 3	256 × 256
	Convolutional	64	3 × 3 / 2	128 × 128
1×	Convolutional	32	1 × 1	
	Convolutional	64	3 × 3	
	Residual			128 × 128
	Convolutional	128	3 × 3 / 2	64 × 64
2×	Convolutional	64	1 × 1	
	Convolutional	128	3 × 3	
	Residual			64 × 64
	Convolutional	256	3 × 3 / 2	32 × 32
8×	Convolutional	128	1 × 1	
	Convolutional	256	3 × 3	
	Residual			32 × 32
	Convolutional	512	3 × 3 / 2	16 × 16
8×	Convolutional	256	1 × 1	
	Convolutional	512	3 × 3	
	Residual			16 × 16
	Convolutional	1024	3 × 3 / 2	8 × 8
4×	Convolutional	512	1 × 1	
	Convolutional	1024	3 × 3	
	Residual			8 × 8
	Avgpool		Global	
	Connected		1000	
	Softmax			

Table 1. **Darknet-53.**

Hình 1. Kiến trúc của backbone Darknet-53 [7]

Darknet-53 được thiết kế dựa trên các khối Residual Block, tương tự kiến trúc ResNet, giúp mạng học sâu hơn mà vẫn giảm hiện tượng mất gradient.

Cấu trúc chính của Darknet-53 bao gồm:

- Convolution layers
- Batch Normalization
- Leaky ReLU activation

- Residual connections

Residual connection có dạng:

$$y = F(x) + x$$

Trong đó:

- x là đầu vào
- $F(x)$là hàm biến đổi qua các lớp convolution

Cơ chế này giúp cải thiện khả năng học của mạng khi số lớp tăng lên.

Multi-Scale Detection

Một cải tiến quan trọng của YOLOv3 là dự đoán đối tượng ở nhiều tỷ lệ khác nhau.[7]

YOLOv3 sử dụng 3 feature maps với kích thước khác nhau để phát hiện đối tượng:

Scale	**Feature Map**	**Mục đích**
Scale 1	13 × 13	phát hiện đối tượng lớn
Scale 2	26 × 26	phát hiện đối tượng trung bình
Scale 3	52 × 52	phát hiện đối tượng nhỏ

Các feature map có độ phân giải cao hơn giúp phát hiện small objects tốt hơn.

YOLOv3 sử dụng kỹ thuật feature pyramid network (FPN) để kết hợp thông tin từ các tầng sâu và nông của mạng.[7]

Anchor Boxes

YOLOv3 sử dụng anchor boxes để dự đoán bounding box[7].

Mỗi grid cell dự đoán:

- 3 anchor boxes

Trong các thí nghiệm trên bộ dữ liệu COCO, mô hình YOLOv3 dự đoán 3 bounding box tại mỗi tỷ lệ (scale). Do đó, đầu ra của mạng tại mỗi scale có dạng tensor $N \times N \times [3 \times (4 + 1 + 80)]$, trong đó:

- 4 giá trị biểu diễn các tham số của bounding box (x, y, w, h),

- 1 giá trị biểu diễn objectness score (xác suất bounding box chứa đối tượng),
- 80 giá trị tương ứng với xác suất của các lớp đối tượng trong bộ dữ liệu COCO. Như vậy, mỗi anchor box sẽ dự đoán tổng cộng 85 tham số. [7]

- Các anchor này được xác định bằng thuật toán k-means clustering trên dataset.

- Mỗi bounding box dự đoán:

(x, y, w, h, objectness, class probabilities)

Trong đó:

- x, y là toạ độ tâm bounding box
- w, h là tọa độ grid cell
- $objectness$ là xác suất chứa object
- $class\ probabilities$ là xác suất các lớp

Công thức dự đoán bounding box

YOLOv3 dự đoán bounding box dựa trên offset so với grid cell.

Các tọa độ được tính như sau:

$$b_x = \sigma(t_x) + c_x$$
$$b_y = \sigma(t_y) + c_y$$
$$b_w = p_w e^{t_w}$$
$$b_h = p_h e^{t_h}$$ [7]

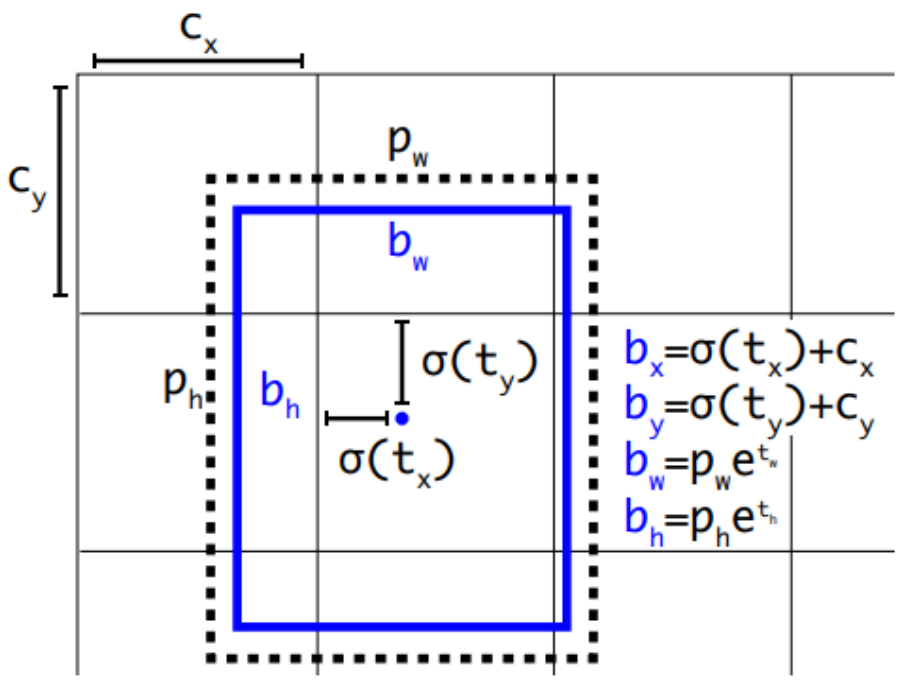

Hình 2. Minh họa cách YOLOv3 dự đoán bounding box từ anchor box và grid cell.[7]

Trong đó:

- t_x, t_y, t_w, t_h là output của mạng
- c_x, c_y là tọa độ grid cell
- p_w, p_h là kích thước anchor box

Hàm loss trong YOLOv3

YOLOv3 tối ưu ba thành phần loss gồm localization loss, objectness loss và classification loss. Bounding box coordinates được học thông qua logistic regression cho tọa độ tâm và exponential transformation cho kích thước bounding box, trong khi objectness và class prediction sử dụng Binary Cross Entropy loss.[7]

Localization Loss

Sai số vị trí bounding box:

$$(x, y, w, h)$$

Objectness Loss

Đánh giá độ tin cậy rằng bounding box chứa đối tượng.

Classification Loss

Dự đoán lớp của đối tượng bằng **Binary Cross Entropy (BCE)**.

Loss function có thể mô tả dưới dạng:

$$L = L_{box} + L_{obj} + L_{class}$$

Non-Maximum Suppression (NMS)

Sau khi mô hình dự đoán nhiều bounding box, thuật toán Non-Maximum Suppression (NMS) được sử dụng để loại bỏ các bounding box trùng lặp.

Quy trình NMS:

1. Sắp xếp bounding box theo confidence score.
2. Chọn box có score cao nhất.
3. Loại bỏ các box có IoU lớn hơn threshold với box đó.
4. Lặp lại cho các box còn lại.

Nhờ đó, hệ thống chỉ giữ lại bounding box tốt nhất cho mỗi đối tượng.

Ưu điểm của YOLOv3

YOLOv3 có nhiều ưu điểm nổi bật:

- Tốc độ phát hiện rất nhanh
- Kiến trúc đơn giản
- Có khả năng phát hiện nhiều đối tượng trong ảnh
- Phù hợp cho các hệ thống thời gian thực

Hạn chế của YOLOv3

Mặc dù hiệu quả, YOLOv3 vẫn có một số hạn chế:

- Khó phát hiện các đối tượng rất nhỏ
- Độ chính xác thấp hơn một số mô hình two-stage
- Phụ thuộc vào anchor boxes

Các chỉ số đánh giá trong Object Detection

Trong các bài toán phát hiện đối tượng, việc đánh giá hiệu quả của mô hình là rất quan trọng. Các chỉ số đánh giá giúp xác định mức độ chính xác của mô hình khi dự đoán vị trí và loại của các đối tượng trong hình ảnh. Một số chỉ số thường được sử dụng trong object detection bao gồm Intersection over Union (IoU), Precision, Recall và Mean Average Precision (mAP).

Intersection over Union (IoU)

Intersection over Union (IoU) là chỉ số dùng để đo mức độ chồng lấp giữa bounding box dự đoán và bounding box thực tế (ground truth).

IoU được tính bằng tỷ lệ giữa diện tích phần giao nhau và diện tích phần hợp của hai bounding box.

$$IoU = \frac{Area\ Of\ Overlap}{Area\ Of\ Union}$$

Trong đó:

- Area of Overlap: diện tích phần giao giữa bounding box dự đoán và bounding box thực.
- Area of Union: tổng diện tích của hai bounding box trừ đi phần giao nhau.

Giá trị IoU nằm trong khoảng:

$0 \leq IoU \leq 1$

- IoU gần **1** → dự đoán rất chính xác
- IoU gần **0** → dự đoán sai lệch nhiều

Trong nhiều bài toán object detection, một dự đoán được xem là **đúng (True Positive)** nếu:

$IoU \geq 0.5$

Precision

Precision đo tỷ lệ dự đoán đúng trong tổng số các dự đoán của mô hình.

Công thức:

$$Precision = \frac{TP}{TP + FP}$$

Trong đó:

- TP (True Positive): dự đoán đúng đối tượng
- FP (False Positive): dự đoán sai đối tượng

Precision cao cho thấy mô hình ít dự đoán sai đối tượng.

Ví dụ: nếu mô hình phát hiện 10 đối tượng và 8 trong số đó là đúng, precision sẽ là:

$$Precision = \frac{8}{10} = 0.8$$

Recall

Recall đo khả năng của mô hình trong việc phát hiện tất cả các đối tượng thực sự tồn tại trong ảnh.

Công thức:

$$Recall = \frac{TP}{TP + FN}$$

Trong đó:

- TP (True Positive): dự đoán đúng
- FN (False Negative): đối tượng có thật nhưng mô hình không phát hiện

Recall cao cho thấy mô hình không bỏ sót nhiều đối tượng.

Ví dụ: nếu trong ảnh có 10 đối tượng nhưng mô hình chỉ phát hiện đúng 7 đối tượng:

$$Recall = \frac{7}{10} = 0.7$$

Precision–Recall Curve

Trong object detection, precision và recall thường được biểu diễn thông qua Precision–Recall Curve (PR Curve).

Đường cong này thể hiện sự thay đổi của precision theo recall khi thay đổi confidence threshold của mô hình.

Thông thường:

- Khi recall tăng → precision có xu hướng giảm
- Khi precision cao → recall thường thấp hơn

PR Curve giúp đánh giá hiệu suất tổng thể của mô hình.

Average Precision (AP)

Average Precision (AP) là diện tích dưới đường cong Precision–Recall.

AP được tính cho từng lớp đối tượng riêng biệt.

Giá trị AP càng cao chứng tỏ mô hình phát hiện đối tượng của lớp đó càng tốt.

Mean Average Precision (mAP)

Mean Average Precision (mAP) là trung bình của AP trên tất cả các lớp đối tượng.

$$mAP = \frac{1}{N}\sum AP_i$$

Trong đó:

- N là số lớp đối tượng
- AP_i là Average Precision của lớp thứ i

mAP là chỉ số quan trọng nhất để đánh giá hiệu quả của mô hình object detection.

mAP@IoU

Trong nhiều benchmark, mAP được tính với các ngưỡng IoU khác nhau.

Ví dụ:

- mAP@0.5: dự đoán đúng nếu IoU ≥ 0.5
- mAP@[0.5:0.95]: trung bình mAP tại nhiều ngưỡng IoU từ 0.5 đến 0.95

mAP@0.5 thường được sử dụng trong dataset PASCAL VOC, trong khi mAP@[0.5:0.95] được sử dụng phổ biến trong dataset COCO.

[1] "What is Object Detection in Computer Vision?," GeeksforGeeks. Accessed: Mar. 05, 2026. [Online]. Available: https://www.geeksforgeeks.org/computer-vision/what-is-object-detection-in-computer-vision/

[2] R. Girshick, J. Donahue, T. Darrell, and J. Malik, "Rich feature hierarchies for accurate object detection and semantic segmentation," Oct. 22, 2014, *arXiv*: arXiv:1311.2524. doi: 10.48550/arXiv.1311.2524.

[3] R. Girshick, "Fast R-CNN," Sep. 27, 2015, *arXiv*: arXiv:1504.08083. doi: 10.48550/arXiv.1504.08083.

[4] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," Jan. 06, 2016, *arXiv*: arXiv:1506.01497. doi: 10.48550/arXiv.1506.01497.

[5] W. Liu *et al.*, "SSD: Single Shot MultiBox Detector," vol. 9905, 2016, pp. 21–37. doi: 10.1007/978-3-319-46448-0_2.

[6] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, "You Only Look Once: Unified, Real-Time Object Detection," May 09, 2016, *arXiv*: arXiv:1506.02640. doi: 10.48550/arXiv.1506.02640.

[7] J. Redmon and A. Farhadi, "YOLOv3: An Incremental Improvement," Apr. 08, 2018, *arXiv*: arXiv:1804.02767. doi: 10.48550/arXiv.1804.02767.